

Analyse des scripts de séries de télévision

Encadrant : Lynda Tamine-Lechani

email : lynda.lechani@irit.fr

Laboratoire : IRIT

1. Descriptif

L'objectif de ce bureau d'études est double :

1) Analyser un corpus de scripts de séries de télévision.

~~2) Analyser les sentiments des dialogues entre acteurs~~

~~— 3) Résumer des conversations, des épisodes à partir des scripts fournis.~~

3) Développer un outil de recherche d'information sur la série de Télévision FRIENDS

Vous travaillerez sur des données réelles (dialogues en formats texte) issues de la série télévisée américaine FRIENDS (<https://fr.wikipedia.org/wiki/Friends>). Cet ensemble de données contient les fichiers textes de tous les scénarios et dialogues de chaque épisode de chaque saison de cette série. L'ensemble de données a été publié par KAGGLE (<https://www.kaggle.com/datasets/blessondensil294/friends-tv-series-screenplay-script>).

Les tâches concerneront : 1) la représentation des dialogues (contenus de types textes); 2) l'analyse des opinions; 3) ~~la catégorisation du langage des acteurs, séries, saisons.~~

Langage/Software : programmation Python, analyse de textes, analyse d'opinions

2. Méthodologie

Étape 1 : Exploration du jeu de données

Qui fait : TOUS- comparer vos résultats

- Tableau statistique récapitulatif : nombre d'acteurs par épisode, série, nombre de scripts, nombre de mots par épisode, nombre d'échanges moyen par acteur
- Fournir un dictionnaire lexical : tableau des statistiques des mots, fréquences par conversation, fréquence par acteur, fréquence par épisode, évolution des fréquences dans le temps (série)
- Identifier des sujets majeurs en utilisant :
 - o En utilisant un lexique de votre choix
 - o En utilisant des clusters de mots représentés sous forme de vecteurs tf-idf des mots
 - o En utilisant des clusters de word embeddings
 - o En utilisant un modèle d'extraction de sujet LDA

Etape 2 Analyse des sentiments des conversations

Qui fait : TOUS-comparer vos résultats

Etape 2 : Accès aux conversations

Groupe 1 : Accès aux acteurs

Objectif : on souhaite éditer pour chaque acteur une fiche descriptive des personnages (acteurs) à travers leur jeu dans les épisodes et saisons. On souhaite particulièrement générer les méta-données suivantes :

- 1) Sujets dominants : par épisode puis par série. Pour cela utiliser une des méthodologies d'extraction de sujets de la partie 1 (LDA, BERT, etc.), centrée cette fois sur chaque acteur/actrice.
- 2) Sentiments de leurs interventions dans les scripts de dialogue : on s'intéressera à 3 catégories *positive, négatif, neutre*. Pour cela, on vous demande :
 - D'utiliser directement un catégoriseur naïf (ex. VADE)
 - D'entraîner un catégoriseur sur un dataset annoté de ces catégories puis les tester sur le corpus FRIENDS, documents associés à chaque acteur.Indiquer la méthodologies de construction du classifieur : entraînement, validation, test et évaluation avec la métrique d'accuracy.
Pour l'entraînement, utiliser ce dataset : <https://www.kaggle.com/datasets/mdismielhossenabir/sentiment-analysis>.
- 3) Réseau : pour chaque acteur, construire un réseau de jeu sur la série où chaque nœud est un acteur et le lien apparait avec un acteur avec qui il a échangé. Le poids du nœud est un temps relatif de conversation, normalisé par la durée des épisodes où ils ont joué ensemble.
Indiquer ainsi pour chaque acteur, les acteurs avec qui il a le plus échangé, et sujets de leurs échanges.
- 4) Question ouverte : comment détecter, par une mesure, quels sont les acteurs principaux d'une épisode ? série ? L'indiquer alors dans sa fiche.

Groupe 2 : Accès aux conversations

Objectif : on souhaite répondre à de questions en langage naturel qui s'intéressent aux sujets des conversations dans les épisodes et saisons. On s'intéresse à 2 types de questions avec des types de réponses attendues :

- a) Des questions de type Q1 où un acteur, une actrice, un lieu, etc. est mentionné : ex. mariage de Ross et Rachel
Sortie attendue : des scripts ordonnés par degré de pertinence en lien avec cette question entre ces acteurs identifié, l'épisode, sujet de l'épisode.
- b) Des questions de type Q2 de contenu : ex. dinde sur la tête.
Sortie attendue : des scripts ordonnés par degré de pertinence en lien avec cette question, l'épisode, sujet de l'épisode.

Dans ce travail, il convient de :

- Extraire les entités nommées de chaque question (nom d'acteur, lieu)
- Représenter les scripts avec les paires des entités/acteurs impliquées, les entités mentionnées dans leurs scripts.
- Faire un filtrage dans le cas des question de type Q1

- Calculer un vecteur de représentation (voir partie 1) pour les questions, les réponses, trier les réponses candidates avec la mesure de cosinus entre ces vecteurs.
- Construire un pool de test de 10 questions (Type 1, type 2) avec des réponses que vous avez identifiées. Évaluez votre système d'accès avec des mesures de précision, rappel.

Question ouverte : Comment se passer de l'extraction des entités nommées et représenter les acteurs puis utiliser ces représentations pour répondre de façon indifférenciée (sans filtrage) aux questions de type 1 et type 2 (utiliser des éléments du travail de la partie 1).

3. Organisation

- Former 2 groupes d'étudiants pour réaliser chaque partie (partie 1, partie 2).
- Désigner un chef de projet.
- Désigner un chef de groupe-partie et un rôle à chaque membre du groupe
- Organiser une réunion par groupe-partie par semaine : identifier les difficultés, évaluer l'avancement, indiquer les informations à remonter au chef de projet
- Organiser une réunion des chefs de groupes toutes les 2 semaines avec le chef projet identifier les difficultés, évaluer l'avancement, indiquer les informations à remonter à l'enseignante
- Constituer un livrable éditable par les membres du groupe
- Dresser un planning de Gantt au début du projet

4. Livrables

- Voir documents à livrer avec M. Dugat
- Voir calendrier de remise des documents avec M. Dugat
- Ce que je demande en livrable final :
 - * Document qui explique le travail réalisé par chaque groupe dans chaque partie (1 seul rendu concerté pour la partie 1)
 - * GhitHub propre, documenté.

5. Ressources (analyse de texte)

<https://pythonspot.com/tokenizing-words-and-sentences-with-nltk/>
<https://www.nltk.org/book/ch01.html>

-