

LDA — Latent Dirichlet Allocation

Fonctionnement et application sur les scripts FRIENDS

Analyse NLP — Projet FRIENDS TV Series

1. C'est quoi le LDA ?

LDA est un algorithme qui identifie automatiquement les thèmes présents dans un ensemble de textes. Son idée de base est simple :

Principe fondamental

"Un document parle de plusieurs thèmes, et chaque thème est défini par des mots qui apparaissent souvent ensemble."

Si les mots wedding, ring, marry, love apparaissent souvent dans les mêmes scènes, LDA comprend qu'ils forment un thème commun → Relations et mariage.

Si baby, pregnant, hospital, born apparaissent ensemble, LDA comprend → Thème : Grossesse et famille.

Contrairement à Word2Vec qui travaille mot par mot, LDA travaille à l'échelle du document — ici, la scène.

2. Comment fonctionne notre pipeline LDA ?

Le pipeline se déroule en 2 grandes fonctions.

Étape 1 — Trouver le nombre optimal de topics (trouverNbOptimalTopics)

Avant d'entraîner le modèle final, on cherche les meilleurs hyperparamètres : combien de topics (n) et quelle valeur d'alpha.

Préparation des données par scène

Chaque scène devient un document. On regroupe tous les tokens de toutes les répliques d'une même scène.

```
tokens_par_scene = (  
    df.groupby(['saison', 'episode', 'scene_num'])['token']  
    .apply(lambda rows: [t for tokens in rows for t in tokens])  
    .tolist()
```

```
)

# Exemple de contenu :
# [ ['love', 'marry', 'wedding', 'ring', 'kiss'],      # scène 1
#   ['baby', 'pregnant', 'hospital', 'born', 'mom'],   # scène 2
#   ['job', 'work', 'boss', 'office', 'audition'], ... ]
```

On conserve aussi les textes nettoyés (texte nettoyer) comme référence de cohérence — nécessaire pour que la métrique `c_v` calcule les co-occurrences dans une fenêtre glissante.

Construction du dictionnaire et filtrage

```
dictionnaire = corpora.Dictionary(textes)
dictionnaire.filter_extremes(no_below=2, no_above=0.65)
corpus = [dictionnaire.doc2bow(texte) for texte in textes]
```

Paramètre	Signification
<code>no_below=2</code>	Le mot doit apparaître dans au moins 2 scènes
<code>no_above=0.65</code>	Le mot ne doit pas apparaître dans plus de 65% des scènes
<code>doc2bow</code>	Convertit chaque scène en liste de (id_mot, fréquence)

Recherche des meilleurs paramètres

```
for n in range(min_topics, max_topics + 1): # 2 à 8 topics
    for alpha in [0.01, 0.05, 0.1, 0.2, 0.3, 'auto']:

        modele = LdaModel(
            corpus=corpus,
            id2word=dictionnaire,
            num_topics=n,
            passes=20,
            alpha=alpha,
            eta='auto',
            random_state=42,
            iterations=400
        )
```

Paramètre	Signification
<code>num_topics</code>	Nombre de thèmes à découvrir
<code>alpha</code>	Distribution des topics par scène (bas = peu de topics par scène, haut = mélange)
<code>eta='auto'</code>	Distribution des mots par topic, apprise automatiquement
<code>passes=20</code>	Nombre de passages complets sur le corpus
<code>iterations=400</code>	Étapes de convergence par passage

Évaluation par cohérence `c_v`

```
coherence = CoherenceModel(
    model=modele,
```

```

texts=textes_ref,
dictionary=dictionnaire_ref,
coherence='c_v',
processes=1
).get_coherence()

```

La cohérence `c_v` mesure si les mots d'un même topic apparaissent souvent ensemble dans les textes. Plus le score est élevé, plus les topics sont interprétables. La combinaison (`n`, `alpha`) avec le score de cohérence le plus élevé est retournée comme meilleure.

Étape 2 — Entraîner le modèle final par saison (LdaParSaison)

Une fois les paramètres optimaux trouvés pour chaque saison, on entraîne le modèle final. Chaque saison a son propre modèle LDA avec ses propres paramètres optimaux.

```

modele = LdaModel(
    corpus=corpus,
    id2word=dictionnaire,
    num_topics=meilleur['n_topics'],
    passes=20,
    iterations=400,
    alpha=meilleur['alpha'],
    eta='auto',
    random_state=42,
)

```

Exemple de résultats obtenus sur FRIENDS (Saison 1)

```

Topic 1 : marcel, monkey, lose, heckle, poker
→ Thème : Marcel le singe + soirée poker

Topic 2 : baby, laundry, relax, mother, wear, father
→ Thème : Vie quotidienne et famille

Topic 3 : carol, franzblau, barry, janice, love
→ Thème : Relations amoureuses passées

Topic 4 : class, kid, shoe, dance, rome
→ Thème : Activités et sorties

```

3. Visualisation avec pyLDAvis

Les topics ont des dizaines de dimensions — impossible à visualiser directement. pyLDAvis représente chaque topic comme un cercle dans un espace 2D.

```

vis_data = pyLDAvis.gensim_models.prepare(
    modele, corpus, dictionnaire, sort_topics=False
)
pyLDAvis.save_html(vis_data, 'results/lda_vis_s01.html')

```

Élément visuel	Signification
Taille du cercle	Importance du topic (proportion dans le corpus)
Distance entre cercles	Similarité entre topics — cercles éloignés = topics distincts
Panneau de droite	Mots les plus représentatifs du topic sélectionné

Des cercles bien séparés indiquent des topics distincts et de bonne qualité.

4. Résumé du flux complet

```
Pipeline complet

1. Dialogues bruts des scripts FRIENDS (texte)
  |
  v
2. Nettoyage + tokenisation (lemmatisation, suppression mots vides)
  |
  v
3. Groupement par scène (chaque scène = un document)
  |
  v
4. Filtrage du vocabulaire (filter_extremes)
  |
  v
5. trouverNbOptimalTopics : teste toutes les combinaisons (n, alpha)
  → évalue chaque modèle par cohérence c_v
  → retourne les meilleurs paramètres par saison
  |
  v
6. ldaParSaison : entraîne le modèle final avec les paramètres optimaux
  → un modèle LDA par saison
  |
  v
7. pyLDavis : visualisation interactive des topics par saison
  |
  v
8. Identification des thèmes majeurs par saison de FRIENDS
```